

● **Optimização de Modelos de Conversão de Ofertas**

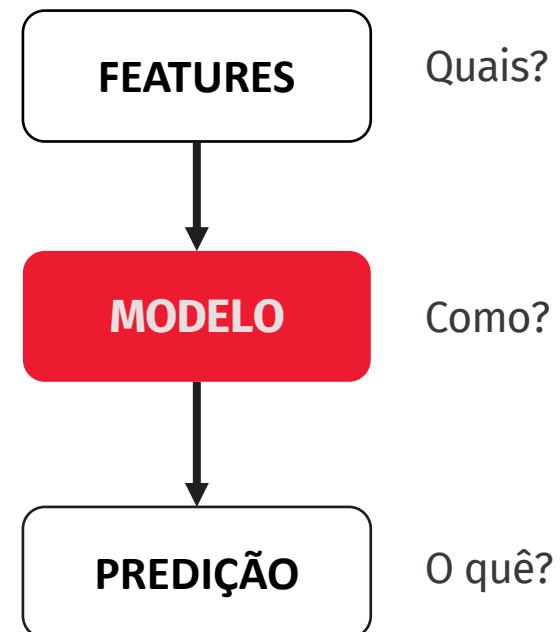
Análise e Modelagem Preditiva utilizando Regressão Logística e XGBoost – Case Ifood

Contexto e Objetivo

- As empresas fazem uso de cupons enviados por meio de vários canais de marketing para **aumentar o engajamento** dos clientes.
- Esse projeto visa desenvolver modelos preditivos para **otimizar campanhas promocionais** e **melhorar a taxa de conversão**.

Estratégia

- Utilização de **regressão logística** e **XGBoost** para prever a probabilidade de aceitação.



Estrutura do Projeto

1

Feature Engineering

Processamento e transformação de variáveis.

2

Treinamento

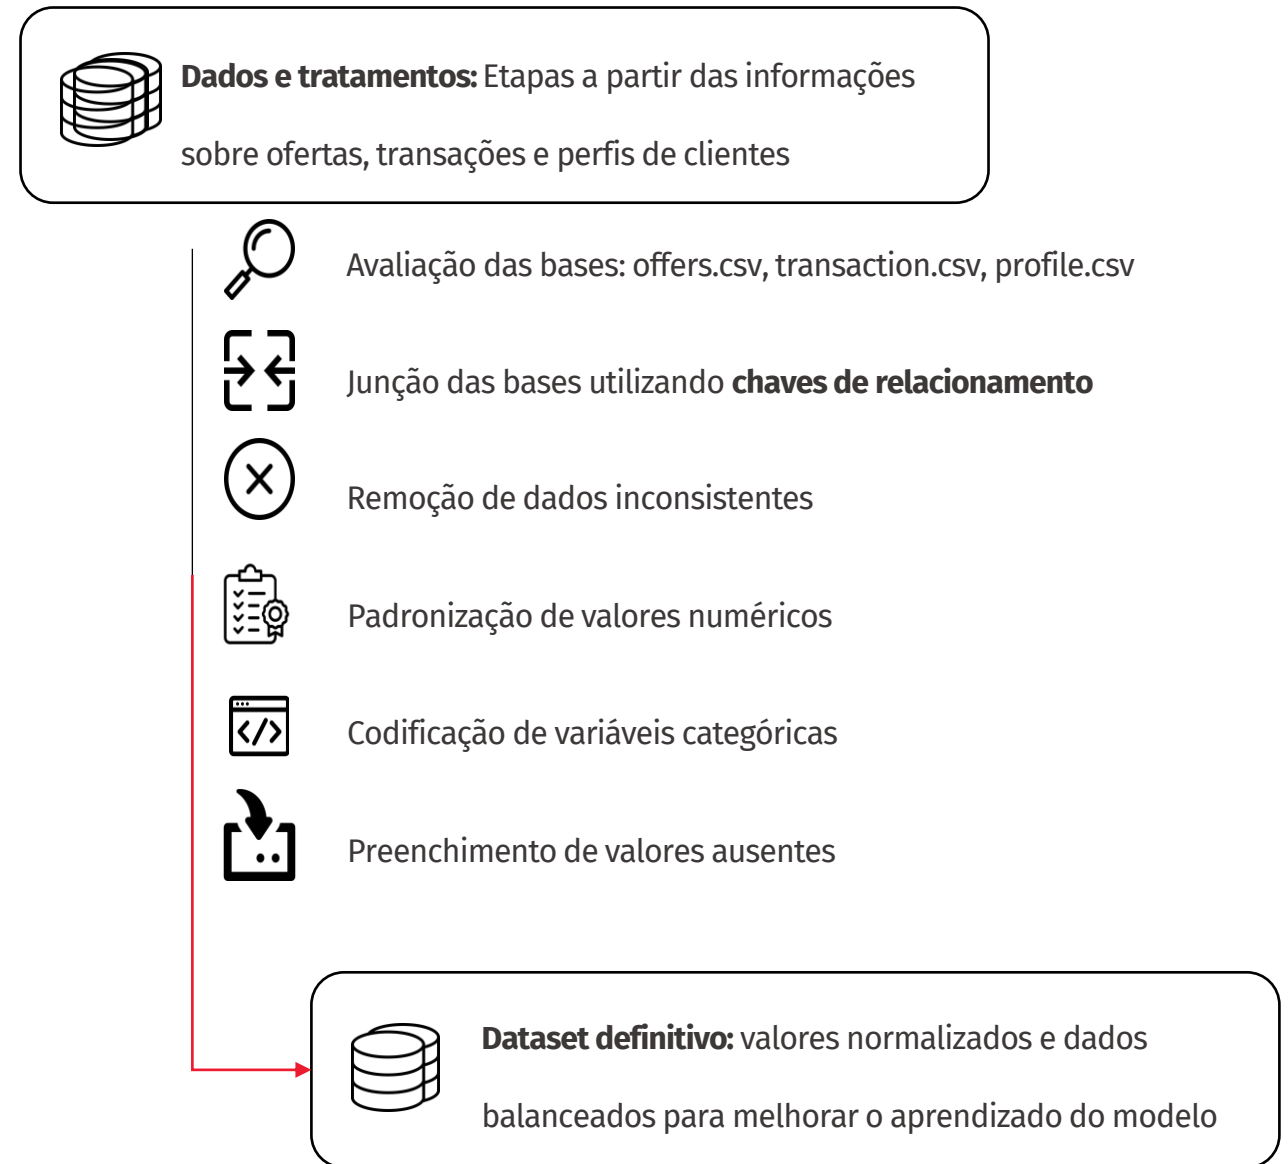
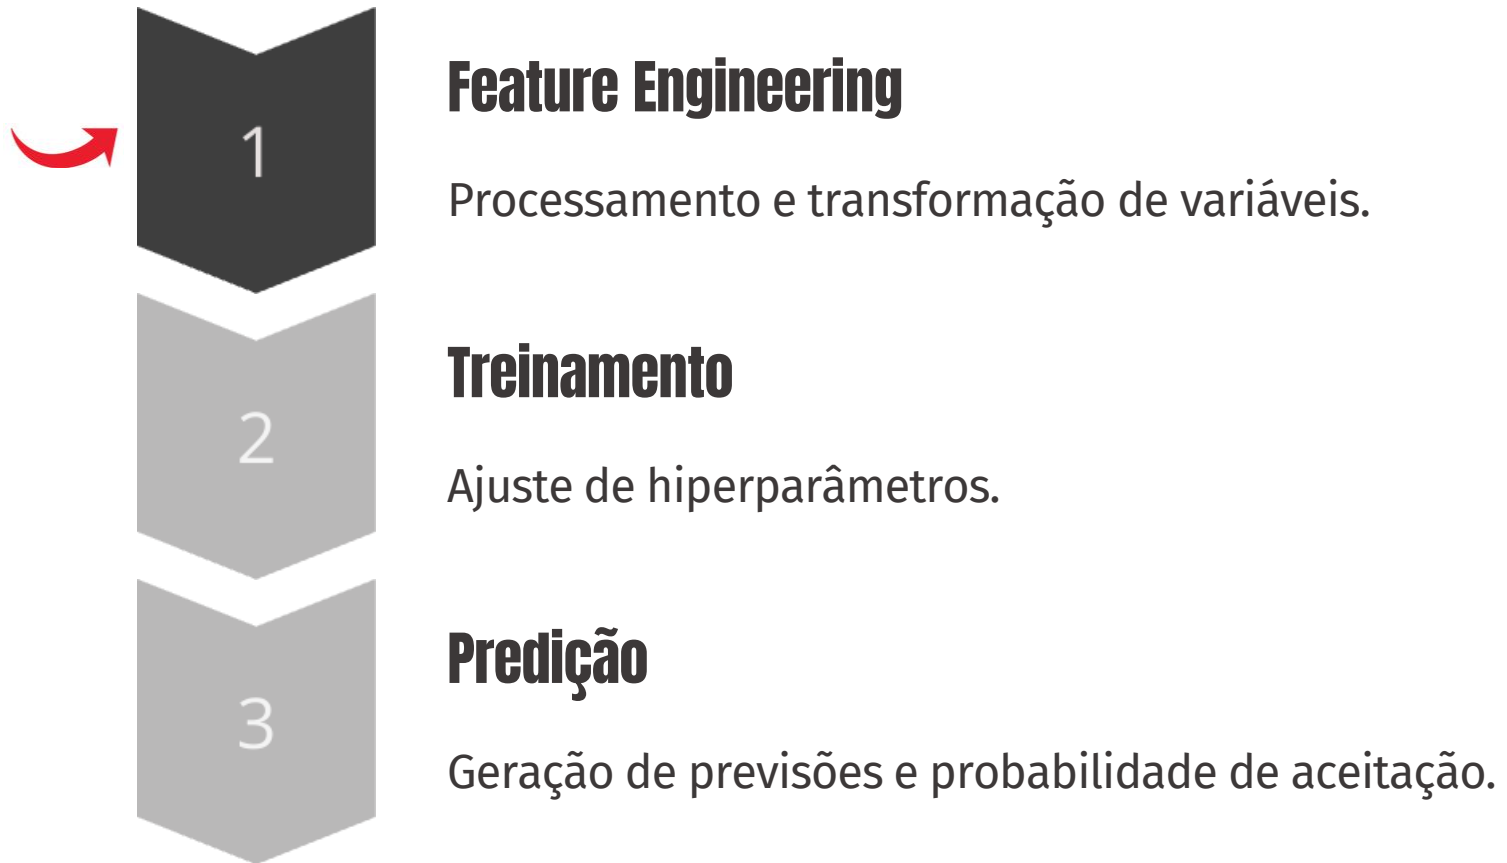
Ajuste de hiperparâmetros.

3

Predição

Geração de previsões e probabilidade de aceitação.

Estrutura do Projeto



Estrutura do Projeto

1

Feature Engineering

Processamento e transformação de variáveis.

2

Treinamento

Ajuste de hiperparâmetros.

3

Predição

Geração de previsões e probabilidade de aceitação.



Modelos e Treinamento: Métodos de treino para construção do modelo preditivo



Modelos utilizados:

Regressão logística, XGBoost, Sistema de Recomendação




Pipeline de Treinamentos:


Engenharia de features com **feat_transformer**

Balanceamento com **SMORTE**

Otimização de hiperparâmetros com **hyperopt**



Treinamento: ajuste dos hiperparâmetros usando a base de validação



Treinamento final na base de treino

Estrutura do Projeto

1

Feature Engineering

Processamento e transformação de variáveis.

2

Treinamento

Ajuste de hiperparâmetros.

3

Predição

Geração de previsões e probabilidade de aceitação.



Métricas de Avaliação: medição do desempenho do modelo



Métricas:

- F1-Score, Precisão, Recall, AUC-ROC



Predição Final: Geração de predictions.csv com
colunas: account_id, offer_id, prediction, probability

Resultados e Próximos Passos

Modelo Treinado

Otimização de hiperparâmetros utilizando **Hyperopt** para Regressão Logística e XGBoost. Implementação de validação cruzada para garantir a robustez do modelo.

Desempenho

Melhor desempenho com **Regressão Logística**, apresentando maior recall e em comparação com o XGBoost. Além de métricas mais equilibradas por classe, melhor acurácia e melhor custo computacional.

Regressão Logística

	precision	recall	f1-score	support
0	0.64	0.69	0.66	9341
1	0.70	0.65	0.67	10390
accuracy			0.67	19731
macro avg	0.67	0.67	0.67	19731
weighted avg	0.67	0.67	0.67	19731

XGBoost

	precision	recall	f1-score	support
0	0.58	0.93	0.72	9341
1	0.86	0.41	0.55	10390
accuracy			0.65	19731
macro avg	0.72	0.67	0.63	19731
weighted avg	0.73	0.65	0.63	19731

Próximos Passos



- Implementação do modelo em um pipeline automatizado para prever a aceitação de ofertas em tempo real;
- Análise de custo-benefício para determinar o impacto financeiro da implementação do modelo;
- Refinar features e buscar melhores resultados no desempenho do modelo;
- Testar outros algoritmos.